

---

# 现代数字信号处理

## 第六讲：自适应滤波（卡尔曼滤波部分）

---

李喆

联系地址：电子楼 357 联系邮箱：lizhe@ suda.edu.cn



苏州大学 电子信息学院

## § 第六讲：自适应滤波（卡尔曼滤波部分）

---

### § 6.5.1 LMS滤波器回顾

### § 6.5.2 从LMS到卡尔曼滤波器

- (1) 随机梯度算法的最优学习增益
- (2) LMS 最优标量步长
- (3) 确定性状态下的Kalman滤波器
- (4) 一般的卡尔曼滤波

### § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

### § 6.5.4 扩展卡尔曼滤波

## § 6.5.1 LMS滤波器回顾

考虑一般的系统辨识设置

$$d(k) = \mathbf{x}^H(k) \mathbf{w}^o(k) + n(k)$$

**目标:**根据受**观测噪声** $n(k)$ 干扰的**期望信号 (Signal of Interest, SOI)**  $d(k)$ 估计**未知确定**系统的参数向量 $\mathbf{w}^o(k)$  (**最优权值向量**)。其中 $\mathbf{x}(k)$ 表示零均值输入向量, $n(k)$ 表示零均值白高斯过程, 方差为 $\sigma_n^2 = E\{n^2(k)\}$ 。该线性模型同样出现在卡尔曼滤波和机器学习中,  $d(k), \mathbf{x}(k)$ 和 $\mathbf{w}^o(k)$ 在不同领域内对应的术语不同。

领域	$d(k)$	$\mathbf{x}(k)$	$\mathbf{w}^o(k)$
自适应滤波	期望信号	输入回归量	最优权值
卡尔曼滤波	观测值	测量值	状态向量
机器学习	目标	特征	假设参数

下面我们从确定性和时不变的最优权值向量 $\mathbf{w}^o(k) = \mathbf{w}^o$ 开始, 回顾LMS算法的推导过程, 给出卡尔曼滤波器。再推广到随机和时变情况下的一般意义上的卡尔曼滤波器。

## § 6.5.1 LMS滤波器回顾

---

LMS需要根据现有的权值向量估计值 $\mathbf{w}(k+1)$ ，期望 $d(k)$ 和输入信号 $\mathbf{x}(k)$ ，递归地估计出最优参数向量 $\mathbf{w}^o$ 。即 $\mathbf{w}(k+1) = f(\mathbf{w}(k), d(k), \mathbf{x}(k))$ 。三者通过输出误差相关联：

$$e(k) = d(k) - \mathbf{x}^H(k)\mathbf{w}(k)$$

定义MSE准则（**输出误差功率**）为

$$\text{MSE} = \xi(k) \triangleq E\{|e(k)|^2\}.$$

LMS算法采用随机梯度下降法，通过最优权值向量 $\mathbf{w}^o$ 以 $\mathbf{w}(k+1) = \mathbf{w}(k) - \mu(k)\nabla_{\mathbf{w}}\xi(k)$ 形式迭代近似最小化式MSE。用瞬时功率代替平均功率， $E\{|e(k)|^2\} \approx |e(k)|^2$ ，LMS的更新方程为

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \Delta\mathbf{w}(k) = \mathbf{w}(k) + \mu(k)\mathbf{x}(k)e(k)$$

## § 6.5.1 LMS滤波器回顾

---

LMS的权值误差向量

$$\tilde{\mathbf{w}}(k) \triangleq \mathbf{w}^o - \mathbf{w}(k),$$

其对输出误差的贡献为

$$e(k) = \mathbf{x}^H(k) \tilde{\mathbf{w}}(k) + n(k).$$

为了与Kalman滤波的条件一致，将 $\mathbf{x}(k)$ 视为一个**确定性**信号，并假设噪声 $n(k)$ 和所有其他变量都是统计独立的。那么MSE可以表示为

$$\begin{aligned} \xi(k) &= E\{|\mathbf{x}^H(k) \tilde{\mathbf{w}}(k) + n(k)|^2\} = \mathbf{x}^H(k) \mathbf{P}(k) \mathbf{x}(k) + \sigma_n^2 \\ &\triangleq \xi_{\text{ex}}(k) + \xi_{\text{min}} \end{aligned}$$

其中 $\mathbf{P}(k) \triangleq E\{\tilde{\mathbf{w}}(k) \tilde{\mathbf{w}}^H(k)\}$ 是误差协方差矩阵。因此，对于迭代的每一步 $k$ ， $\text{MSE} \xi(k)$ 都由两项组成：时变的**超量MSE (EMSE)**  $\xi_{\text{ex}}(k)$ 和观测噪声功率 $\xi_{\text{min}} = \sigma_n^2$ 。

## § 6.5.1 LMS滤波器回顾

---

评估辨识最优系统参数 $\mathbf{w}^o$ 时性能的另一指标是**均方偏差 (MSD)**

$$\text{MSD} = J(k) \triangleq E\{\|\tilde{\mathbf{w}}(k)\|^2\} = E\{\tilde{\mathbf{w}}^H(k)\tilde{\mathbf{w}}(k)\} = \text{Tr}\{\mathbf{P}(k)\}.$$


MSD表示权值误差向量的功率，通过权值误差协方差矩阵 $\mathbf{P}(k) = E\{\tilde{\mathbf{w}}(k)\tilde{\mathbf{w}}^H(k)\}$ 观察到MSD与MSE相关，因此最小化MSD也能对应到最小化MSE。

## § 6.5.2 从LMS到卡尔曼滤波器

### (1) 随机梯度算法的最优学习增益

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \Delta \mathbf{w}(k) = \mathbf{w}(k) + \mu(k)\mathbf{x}(k)e(k)$$

对于LMS的更新方程，参数 $\mu(k)$ 是一个可能随时间变化的正步长，用于控制算法的自适应步长的大小。由于权值更新 $\Delta \mathbf{w}(k) = \mu(k)\mathbf{x}(k)e(k)$ 和输入信号向量 $\mathbf{x}(k)$ 方向相同，这使得LMS对数据中的离群值和噪声十分敏感。



梯度下降会执行局部最优步骤，但是却无法沿着全局最优的最短路径找到解 $\mathbf{w}^o$ 。因此，必须同时控制自适应步骤的**方向**和**幅度**才能使算法遵循最短的最优路径，达到误差曲面的全局最小值 $\xi(\mathbf{w}^o)$ 。

## § 6.5.2 从LMS到卡尔曼滤波器

---

**卡尔曼滤波器**的**第一步**是通过用一个**正定的学习增益矩阵** $\mathbf{G}(k)$ 代替标量步长 $\mu(k)$ 引入更多自由度，从而控制梯度下降适应的大小和方向，并遵循上图中的**最优路径**。因此，更新方程变为

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \mathbf{G}(k)\mathbf{x}(k)e(k)$$

与通过 $\partial\xi(k)/\partial\mu(k)$ 最小化MSE的标准梯度自适应步长方法不同，卡尔曼的目标是在直接**最小化MSD**的基础上，在LMS中引入一个**最优步长**（学习增益）。考虑一般的迭代权值估计器

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \mathbf{g}(k)e(k)$$

其中增益向量为

$$\mathbf{g}(k) \triangleq \begin{cases} \mu(k)\mathbf{x}(k), & \text{对于传统的LMS,} \\ \mathbf{G}(k)\mathbf{x}(k), & \text{对于一般的LMS.} \end{cases}$$



## § 6.5.2 从LMS到卡尔曼滤波器

为了**最小化MSD**，首先建立一般LMS的权值误差向量迭代式，在一般LMS的权值误差向量迭代式两边同时减去 $\mathbf{w}^o$ 并用 $e(k) = \mathbf{x}^H(k)\tilde{\mathbf{w}}(k) + n(k)$ 代替输出误差，得到

$$\tilde{\mathbf{w}}(k+1) = \tilde{\mathbf{w}}(k) - \mathbf{g}(k)\mathbf{x}^H(k)\tilde{\mathbf{w}}(k) - \mathbf{g}(k)n(k).$$

此时，权值误差协方差矩阵 $\mathbf{P}(k)$ 的迭代式是将式上式**两边分别乘各自共轭转置并取统计期望** $E\{\cdot\}$ 得到

$$\begin{aligned}\mathbf{P}(k+1) &= E\{\tilde{\mathbf{w}}(k+1)\tilde{\mathbf{w}}^H(k+1)\} \\ &= \mathbf{P}(k) - \left( \mathbf{P}(k)\mathbf{x}(k)\mathbf{g}^H(k) + \mathbf{g}(k)\mathbf{x}^H(k)\mathbf{P}(k) \right) \\ &\quad + \mathbf{g}(k)\mathbf{g}^H(k) \left( \mathbf{x}^H(k)\mathbf{P}(k)\mathbf{x}(k) + \sigma_n^2 \right)\end{aligned}$$

根据矩阵迹的性质得到

$$\text{Tr}\{\mathbf{P}(k)\mathbf{x}(k)\mathbf{g}^H(k)\} = \mathbf{g}^H(k)\mathbf{P}(k)\mathbf{x}(k)$$

且 $\text{Tr}\{\mathbf{g}(k)\mathbf{g}^H(k)\} = \|\mathbf{g}(k)\|^2$ ，那么MSD  $J(k) = \text{Tr}\{\mathbf{P}(k)\}$ 的迭代式为

$$\begin{aligned}J(k+1) &= J(k) - \mathbf{g}^H(k)\mathbf{P}(k)\mathbf{x}(k) - \mathbf{x}^H(k)\mathbf{P}(k)\mathbf{g}(k) \\ &\quad + \|\mathbf{g}(k)\|^2 (\mathbf{x}^H(k)\mathbf{P}(k)\mathbf{x}(k) + \sigma_n^2)\end{aligned}$$

## § 6.5.2 从LMS到卡尔曼滤波器

### (2) LMS最优标量步长(与NLMS的关系)

LMS的最优步长是为了实现 $e(k+1|k) = d(k) - \mathbf{x}^H(k)\mathbf{w}(k) = 0$ ，其中使用更新的权值向量 $\mathbf{w}(k)$ 和当前输入 $\mathbf{x}(k)$ 得到后验误差 $e(k+1|k)$ 。这种方法也叫NLMS，即

$$\text{NLMS: } \mathbf{w}(k+1) = \mathbf{w}(k) + \frac{1}{\|\mathbf{x}(k)\|^2} \mathbf{x}(k)e(k)$$

有效的LMS型步长 $\mu(k) = \frac{1}{\|\mathbf{x}(k)\|^2}$ 是时变的，实际中往往引入小的正步长 $\rho(k)$ 使算法稳定，即 $\mu(k) = \frac{\rho(k)}{\|\mathbf{x}(k)\|^2}$ 。如果使MSD最小化，得到LMS的最优标量步长，首先将增益 $\mathbf{g}(k) = \mu(k)\mathbf{x}(k)$ 代入 $J(k)$ 迭代式，给出MSD的迭代式

$$\begin{aligned} J(k+1) = J(k) - 2\mu(k) \underbrace{\mathbf{x}^H(k)\mathbf{P}(k)\mathbf{x}(k)}_{\xi_{\text{ex}}(k)} \\ + \mu^2(k) \|\mathbf{x}(k)\|^2 \underbrace{(\mathbf{x}^H(k)\mathbf{P}(k)\mathbf{x}(k) + \sigma_n^2)}_{\xi(k)} \end{aligned}$$

## § 6.5.2 从LMS到卡尔曼滤波器

---

通过 $\frac{\partial J(k)}{\partial \mu(k)} = 0$ 解得上式中的 $\mu(k)$ 来获得最小化MSD的最优步长,

$$\mu(k) = \frac{1}{\|\mathbf{x}(k)\|^2} \frac{\mathbf{x}^H(k) \mathbf{P}(k) \mathbf{x}(k)}{(\mathbf{x}^H(k) \mathbf{P}(k) \mathbf{x}(k) + \sigma_n^2)} = \underbrace{\frac{1}{\|\mathbf{x}(k)\|^2}}_{\text{normalization}} \underbrace{\frac{\xi_{\text{ex}}(k)}{\xi(k)}}_{\text{correction}}$$

除了NLMS型归一化因子 $\frac{1}{\|\mathbf{x}(k)\|^2}$ , 最优LMS步长包含修正项 $\frac{\xi_{\text{ex}}(k)}{\xi(k)} < 1$ , 表示EMSE $\xi_{\text{ex}}(k)$ 与MSE $\xi(k)$ 的比率。与真实系统权值的较大偏差导致了较大的 $\frac{\xi_{\text{ex}}(k)}{\xi(k)}$ 和较快的权值调整（与较小 $\frac{\xi_{\text{ex}}(k)}{\xi(k)}$ 引起的较慢调整相比）。

## § 6.5.2 从LMS到卡尔曼滤波器

### (3) 确定性状态下的Kalman滤波器

在第(2)步，最优LMS步长旨在每一个瞬时时刻都最小化MSD，它**只能控制梯度步长的大小**。为了同时控制梯度下降的大小和方向，回到MSD的表达式。通过 $\frac{\partial J(k)}{\partial \mathbf{g}(k)} = 0$ 解得上述MSD的 $\mathbf{g}(k)$ ，从而得到最优学习增益向量 $\mathbf{g}(k)$ ，即

$$\mathbf{g}(k) = \frac{\mathbf{P}(k)}{\mathbf{x}^H(k)\mathbf{P}(k)\mathbf{x}(k) + \sigma_n^2}\mathbf{x}(k) = \frac{\mathbf{P}(k)}{\xi(k)}\mathbf{x}(k) = \mathbf{G}(k)\mathbf{x}(k)$$

这个最优增益向量 $\mathbf{g}(k)$ 就是**卡尔曼增益**，而**增益矩阵** $\mathbf{G}(k)$ 表示权值误差协方差矩阵 $\mathbf{P}(k)$ 与MSE $\xi(k)$ 之间的比值。此时权误差协方差矩阵的 $\mathbf{P}(k)$ 的更新方程变为

$$\begin{aligned}\mathbf{P}(k+1) &= \mathbf{P}(k) - \left( \mathbf{P}(k)\mathbf{x}(k)\mathbf{g}^H(k) + \mathbf{g}(k)\mathbf{x}^H(k)\mathbf{P}(k) \right) \\ &\quad + \mathbf{g}(k)\mathbf{g}^H(k) \left( \mathbf{x}^H(k)\mathbf{P}(k)\mathbf{x}(k) + \sigma_n^2 \right) \\ &= \mathbf{P}(k) - \mathbf{g}(k)\mathbf{x}^H(k)\mathbf{P}(k)\end{aligned}$$

## § 6.5.2 从LMS到卡尔曼滤波器

---

通过更新 $\mathbf{P}(k)$ 就可以得到卡尔曼滤波器，即：

1) 计算最优学习增益（卡尔曼增益）：

$$\mathbf{g}(k) = \mathbf{P}(k)\mathbf{x}(k)/(\mathbf{x}^H(k)\mathbf{P}(k)\mathbf{x}(k) + \sigma_n^2)$$

2) 更新权值向量：

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \mathbf{g}(k)(d(k) - \mathbf{x}^H(k)\mathbf{w}(k))$$

3) 更新权值误差协方差矩阵：

$$\mathbf{P}(k+1) = \mathbf{P}(k) - \mathbf{g}(k)\mathbf{x}^H(k)\mathbf{P}(k)$$


注意：对于 $\sigma_n^2 = 1$ ，上述算法的更新公式与递归最小二乘（RLS）算法一致。

## § 6.5.2 从LMS到卡尔曼滤波器

### (4) 一般的卡尔曼滤波

下面考虑权值向量 $\mathbf{w}^o(k)$ 时变的情况，从最优LMS导出一般卡尔曼滤波的算法。考虑真实的权值向量 $\mathbf{w}^o(k)$ 的演变由已知的**状态转换矩阵** $\mathbf{F}(k)$ 控制，而状态转换中的不确定性由协方差为 $\mathbf{Q}_s = E\{\mathbf{q}(k)\mathbf{q}^H(k)\}$ 的噪声向量 $\mathbf{q}(k)$ 表示，其与观测噪声 $n(k)$ **不相关**。那么

$$\mathbf{w}^o(k+1) = \mathbf{F}(k)\mathbf{w}^o(k) + \mathbf{q}(k), \quad \mathbf{q}(k) \sim \mathcal{N}(0, \mathbf{Q}_s)$$



## § 6.5.2 从LMS到卡尔曼滤波器

---

系统辨识模型仍为:

$$d(k) = \mathbf{x}^H(k) \mathbf{w}^o(k) + n(k), \quad n(k) \sim \mathcal{N}(0, \sigma_n^2)$$

最优权值向量的更新分两步

1) 以当前状态值 $\mathbf{w}(k|k)$ 预测下一状态 $\mathbf{w}(k+1|k)$

$$\mathbf{w}(k+1|k) = \mathbf{F}(k) \mathbf{w}(k|k),$$

2) 以类似LMS方式更新下一状态估计值 $\mathbf{w}(k+1|k+1)$

$$\mathbf{w}(k+1|k+1) = \mathbf{w}(k+1|k) + \mathbf{g}(k)[d(k) - \mathbf{x}^H(k) \mathbf{w}(k+1|k)],$$

其中  $\mathbf{g}(k)$  是卡尔曼增益。

## § 6.5.2 从LMS到卡尔曼滤波器

---

所有相关量的更新步骤（用 $k|k$ 表示）和预测步骤（用 $k+1|k$ 表示）定义如下

$$\tilde{\mathbf{w}}(k|k) \triangleq \mathbf{w}^o(k) - \mathbf{w}(k|k),$$

$$\mathbf{P}(k|k) \triangleq E\{\tilde{\mathbf{w}}(k|k)\tilde{\mathbf{w}}^H(k|k)\},$$

$$\tilde{\mathbf{w}}(k+1|k) \triangleq \mathbf{w}^o(k+1) - \mathbf{w}(k+1|k) = \mathbf{F}(k)\tilde{\mathbf{w}}(k|k) + \mathbf{q}(k),$$

$$\begin{aligned}\mathbf{P}(k+1|k) &\triangleq E\{\tilde{\mathbf{w}}(k+1|k)\tilde{\mathbf{w}}^H(k+1|k)\} \\ &= \mathbf{F}(k)\mathbf{P}(k|k)\mathbf{F}^H(k) + \mathbf{Q}_s.\end{aligned}$$

因此，权值误差向量的更新公式为

$$\tilde{\mathbf{w}}(k+1|k+1) = \tilde{\mathbf{w}}(k+1|k) - \mathbf{g}(k)\mathbf{x}^H(k)\tilde{\mathbf{w}}(k+1|k) - \mathbf{g}(k)n(k),$$



## § 6.5.2 从LMS到卡尔曼滤波器

---

从而得到权值误差协方差的迭代式为

$$\begin{aligned}\mathbf{P}(k+1|k+1) &\triangleq E\{\tilde{\mathbf{w}}(k+1|k+1)\tilde{\mathbf{w}}^H(k+1|k+1)\} \\ &= \mathbf{P}(k+1|k) - [\mathbf{P}(k+1|k)\mathbf{x}(k)\mathbf{g}^H(k) + \mathbf{g}(k)\mathbf{x}^H(k)\mathbf{P}(k+1|k)] \\ &\quad + \mathbf{g}(k)\mathbf{g}^H(k)[\mathbf{x}^H(k)\mathbf{P}(k+1|k)\mathbf{x}(k) + \sigma_n^2]\end{aligned}$$

最后，最小化MSD  $J(k|k) = \text{Tr}\{\mathbf{P}(k+1|k+1)\}$ ，得到卡尔曼增益 $\mathbf{g}(k)$ 的表达式为

$$\mathbf{g}(k) = \frac{\mathbf{P}(k+1|k)}{\mathbf{x}^H(k)\mathbf{P}(k+1|k)\mathbf{x}(k) + \sigma_n^2}\mathbf{x}(k) = \mathbf{G}(k)\mathbf{x}(k)$$

其与最优LMS增益相同。

## § 6.5.2 从LMS到卡尔曼滤波器

---

一般卡尔曼滤波器的算法步骤：对于每个时刻 $k > 0$ ，基于测量值 $\{d(k), \mathbf{x}(k)\}$ 有

- 1) 预测下一个（后验）权值向量（状态）：

$$\mathbf{w}(k+1|k) = \mathbf{F}(k)\mathbf{w}(k|k)$$

- 2) 预测权值误差协方差矩阵：

$$\mathbf{P}(k+1|k) = \mathbf{F}(k)\mathbf{P}(k|k)\mathbf{F}^H(k) + \mathbf{Q}_s$$

- 3) 计算最优学习增益（卡尔曼增益）：

$$\mathbf{g}(k) = \mathbf{P}(k+1|k)\mathbf{x}(k)/(\mathbf{x}^H(k)\mathbf{P}(k+1|k)\mathbf{x}(k) + \sigma_n^2)$$

- 4) 更新权值向量估计：

$$\mathbf{w}(k+1|k+1) = \mathbf{w}(k+1|k) + \mathbf{g}(k)(d(k) - \mathbf{x}^H(k)\mathbf{w}(k+1|k))$$

- 5) 更新权值误差协方差矩阵：

$$\mathbf{P}(k+1|k+1) = \mathbf{P}(k+1|k) - \mathbf{g}(k)\mathbf{x}^H(k)\mathbf{P}(k+1|k)$$

## § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

**贝叶斯理论:**  $P(X|Z)P(Z) = P(Z|X)P(X)$ , 其中 $P(X)$ 为**先验分布**,  $P(Z|X)$ 为**似然函数**。

$P(X|Z)$ 为**后验分布**, 表示结合观测信息后的状态概率更新。卡尔曼滤波可看作是贝叶斯更新在线性高斯动态系统中的具体实现, 包括**先验更新 (预测阶段)**和**后验更新 (修正阶段)**。Kalman滤波器的**两个方程**:

$$\begin{cases} \text{矢量状态方程: } \mathbf{x}(n) = \mathbf{A}(n-1)\mathbf{x}(n-1) + \mathbf{q}(n) \\ \text{矢量观测方程: } \mathbf{y}(n) = \mathbf{C}(n)\mathbf{x}(n) + \mathbf{v}(n) \end{cases}$$

**定义:** 推导中用  $\hat{\mathbf{x}}(n/n)$  表示给定  $i = 1, 2, \dots, n$  的观测  $\mathbf{y}(i)$  而在时刻  $n$  获得的  $\mathbf{x}(n)$  的最佳线性估计, 用  $\hat{\mathbf{x}}(n/n-1)$  表示给定  $i = 1, 2, \dots, n-1$  的观测  $\mathbf{y}(i)$  时  $\mathbf{x}(n)$  的最佳估计。

用  $\mathbf{e}(n/n)$  和  $\mathbf{e}(n/n-1)$  表示相应的**状态估计误差**:

$$\mathbf{e}(n/n) = \mathbf{x}(n) - \hat{\mathbf{x}}(n/n)$$

$$\mathbf{e}(n/n-1) = \mathbf{x}(n) - \hat{\mathbf{x}}(n/n-1)$$

**误差协方差阵定义为:**

$$\begin{cases} \mathbf{P}(n/n) = E \left\{ \mathbf{e}(n/n) \mathbf{e}^H(n/n) \right\} \\ \mathbf{P}(n/n-1) = E \left\{ \mathbf{e}(n/n-1) \mathbf{e}^H(n/n-1) \right\} \end{cases}$$

## § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

---

### 整体求解过程一迭代实现

- 假设给定  $\mathbf{x}(0)$  的一个估计  $\hat{\mathbf{x}}(0/0)$ ，相应于这一估计的误差协方差阵  $\mathbf{P}(0/0)$  也已知。

- 当观测值  $\mathbf{y}(1)$  到来时，要修正  $\hat{\mathbf{x}}(0/0)$  以获得  $n=1$  时刻的状态估计  $\hat{\mathbf{x}}(1/1)$ ，并使如下均方误差最小：

$$\xi(1) = E \{ \|\mathbf{e}(1/1)\|^2 \} = \text{tr} \{ \mathbf{P}(1/1) \} = \sum_{i=0}^{p-1} E \{ |e_i(1/1)|^2 \}$$

- 确定  $\hat{\mathbf{x}}(1/1)$  后，就可得到误差协方差阵  $\mathbf{P}(1/1)$ ，再随着观测值  $\mathbf{y}(2)$  的到来重复以上估计过程。……到第  $n$  步；直到稳态收敛，并保持、跟踪。

## § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

---

### 每次迭代求解

- 这样对每个  $n > 0$  , 给定  $\hat{\mathbf{x}}(n-1/n-1)$  和  $\mathbf{P}(n-1/n-1)$  , 当新观测值  $\mathbf{y}(n)$  到来时, 要求解状态矢量  $\mathbf{x}(n)$  新的最小均方误差估计  $\hat{\mathbf{x}}(n/n)$  。
- **求解该问题可分为两步:**
- **第一步是预测估计**, 由  $\hat{\mathbf{x}}(n-1/n-1)$  获得  $\hat{\mathbf{x}}(n/n-1)$  , 它是无  $\mathbf{y}(n)$  观测值时  $\mathbf{x}(n)$  的最佳估计;
- **第二步是滤波估计**, 由  $\mathbf{y}(n)$  和  $\hat{\mathbf{x}}(n/n-1)$  的最优组合来估计  $\mathbf{x}(n)$  。

### § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

**第一步:** 无新观测值, 只能利用  $\mathbf{x}(n)$  状态方程:

$\mathbf{x}(n) = \mathbf{A}(n-1)\mathbf{x}(n-1) + \mathbf{q}(n)$ , 得  $\mathbf{x}(n)$  的预测估计:

$$\hat{\mathbf{x}}(n/n-1) = \mathbf{A}(n-1)\hat{\mathbf{x}}(n-1/n-1)$$

$$\mathbf{e}(n/n-1) = \mathbf{x}(n) - \hat{\mathbf{x}}(n/n-1)$$

**误差为:**  $= \mathbf{A}(n-1)\mathbf{x}(n-1) + \mathbf{q}(n) - \mathbf{A}(n-1)\hat{\mathbf{x}}(n-1/n-1)$

$$= \mathbf{A}(n-1)\mathbf{e}(n-1/n-1) + \mathbf{q}(n)$$

→ 因  $\mathbf{q}(n)$  均值为零, 若  $\hat{\mathbf{x}}(n-1/n-1)$  是无偏估计, 即

$E\{\mathbf{e}(n-1/n-1)\} = 0$ , 则  $\hat{\mathbf{x}}(n/n-1)$  也是  $\mathbf{x}(n)$  的无偏估计, 即:

$$E\{\mathbf{e}(n/n-1)\} = 0.$$

最后, 因估计误差  $\mathbf{e}(n-1/n-1)$  与  $\mathbf{q}(n)$  不相关,  $\mathbf{q}(n)$  是白噪声序列, 因此:

$\mathbf{P}(n/n-1) = \mathbf{A}(n-1)\mathbf{P}(n-1/n-1)\mathbf{A}^H(n-1) + \mathbf{Q}_q(n)$  其中  $\mathbf{Q}_q(n)$  是噪声  $\mathbf{q}(n)$  的协方差阵。 **以上即卡尔曼滤波第一步。**

## § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

**第二步:** 要将新观测  $\mathbf{y}(n)$  与  $\hat{\mathbf{x}}(n/n-1)$  结合**得到新估计:**

$$\hat{\mathbf{x}}(n/n) = \mathbf{K}'(n)\hat{\mathbf{x}}(n/n-1) + \mathbf{K}(n)\mathbf{y}(n)$$

其中  $\mathbf{K}(n)$  和  $\mathbf{K}'(n)$  是要确定的矩阵。

1) 首先由  $\mathbf{x}(n)$  估计的无偏性得  $\mathbf{K}(n)$  和  $\mathbf{K}'(n)$  的关系

$\hat{\mathbf{x}}(n/n)$  无偏  $\Leftrightarrow E\{\mathbf{e}(n/n)\} = 0$ . 由(I)  $\rightarrow$  用  $\mathbf{e}(n/n-1)$  表达的  $\mathbf{e}(n/n)$  :

$$\begin{aligned}\mathbf{e}(n/n) &= \mathbf{x}(n) - \mathbf{K}'(n)\hat{\mathbf{x}}(n/n-1) - \mathbf{K}(n)\mathbf{y}(n) \\ &= \mathbf{x}(n) - \mathbf{K}'(n)[\mathbf{x}(n) - \mathbf{e}(n/n-1)] - \mathbf{K}(n)[\mathbf{C}(n)\mathbf{x}(n) + \mathbf{v}(n)] \\ &= [\mathbf{I} - \mathbf{K}'(n) - \mathbf{K}(n)\mathbf{C}(n)]\mathbf{x}(n) + \mathbf{K}'(n)\mathbf{e}(n/n-1) - \mathbf{K}(n)\mathbf{v}(n)\end{aligned}$$

由于  $E\{\mathbf{v}(n)\} = 0, E\{\mathbf{e}(n/n-1)\} = 0$  , 若要上式的  $E\{\mathbf{e}(n/n)\} = 0$  , 必须满足:  $\mathbf{K}'(n) = \mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)$

代入(I)得:  $\hat{\mathbf{x}}(n/n) = [\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]\hat{\mathbf{x}}(n/n-1) + \mathbf{K}(n)\mathbf{y}(n)$

重组:  $\hat{\mathbf{x}}(n/n) = \hat{\mathbf{x}}(n/n-1) + \mathbf{K}(n)[\mathbf{y}(n) - \mathbf{C}(n)\hat{\mathbf{x}}(n/n-1)]$

### § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

**2)再由**  $\min E \{ \|e(n/n)\|^2 \} = \min \text{tr}\{\mathbf{P}(n/n)\}$  **准则得最优**  $\mathbf{K}(n)$  :误差准则:  $\xi(n) = \text{tr}\{\mathbf{P}(n/n)\}$ , 用  $d\xi/d\mathbf{K}(n) = 0$  求解  $\mathbf{K}(n)$  。

**误差:**

$$\begin{aligned} e(n/n) &= \mathbf{K}'(n)e(n/n-1) - \mathbf{K}(n)\mathbf{v}(n) \\ &= [\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]e(n/n-1) - \mathbf{K}(n)\mathbf{v}(n) \end{aligned}$$

因  $\mathbf{v}(n)$  与  $\mathbf{q}(n)$  (即  $\mathbf{x}(n)$ ) 不相关, 也与  $\hat{\mathbf{x}}(n/n-1)$  不相关, 而  $e(n/n-1) = \mathbf{x}(n) - \hat{\mathbf{x}}(n/n-1)$ , 故上式中  $\mathbf{v}(n)$  与  $e(n/n-1)$  也不相关。  $\rightarrow$

$$\begin{aligned} \mathbf{P}(n/n) &= E \{ e(n/n)e^H(n/n) \} \\ &= [\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]\mathbf{P}(n/n-1)[\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]^H + \mathbf{K}(n)\mathbf{Q}_v(n)\mathbf{K}^H(n) \end{aligned}$$

**再给一些公式:**  $\frac{d}{d\mathbf{K}} \text{tr}(\mathbf{K}\mathbf{A}\mathbf{K}^H) = 2\mathbf{K}\mathbf{A}, \frac{d}{d\mathbf{K}} \text{tr}(\mathbf{K}\mathbf{A}) = \mathbf{A}^H$



### § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

最后得式(II):

$$\frac{d}{d\mathbf{K}} \text{tr}[\mathbf{P}(n/n)] = -2[\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]\mathbf{P}(n/n-1)\mathbf{C}^H(n) + 2\mathbf{K}(n)\mathbf{Q}_v(n) = 0$$

求得:

$$\mathbf{K}(n) = \mathbf{P}(n/n-1)\mathbf{C}^H(n) \left[ \mathbf{C}(n)\mathbf{P}(n/n-1)\mathbf{C}^H(n) + \mathbf{Q}_v(n) \right]^{-1}$$

导出卡尔曼增益矢量后, 可用它再简化前面误差协方差阵  $\mathbf{P}(n/n)$  的表达式, 得:

$$\begin{aligned} \mathbf{P}(n/n) &= [\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]\mathbf{P}(n/n-1) \\ &\quad - \left\{ [\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]\mathbf{P}(n/n-1)\mathbf{C}^H(n) + \mathbf{K}(n)\mathbf{Q}_v(n) \right\} \mathbf{K}^H(n) \end{aligned}$$

上式第2项应为零,  $\mathbf{P}(n/n)$  可简化为:

$$\mathbf{P}(n/n) = [\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]\mathbf{P}(n/n-1)$$

至此已得估计  $\mathbf{x}(n)$  的卡尔曼滤波递归式.

### § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

---

**剩下问题是  $n = 0$  时的初始化问题。**

因初始状态值未知, 在没有  $n = 0$  时刻观测数据时, 可选择初始状态估计为:  $\hat{\mathbf{x}}(0/0) = E\{\mathbf{x}(0)\}$

而对误差协方差阵, 初始值取为:

$$\mathbf{P}(0/0) = E\{\mathbf{x}(0)\mathbf{x}^H(0)\}$$

这种选择使得  $\hat{\mathbf{x}}(0/0)$  是  $\mathbf{x}(0)$  的无偏估计, 从而保证对所有的  $n$ ,  $\hat{\mathbf{x}}(n/n)$  是无偏的(注意推导卡尔曼迭代方程时, 约束了  $\hat{\mathbf{x}}(n/n)$  是无偏的)。

**另有一点要注意:** 卡尔曼增益  $\mathbf{K}(n)$  和误差协方差阵  $\mathbf{P}(n/n)$  的递归估计与数据  $\mathbf{x}(n)$  无关, 故可离线预先计算出来, 用于任意数据滤波。

## § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

### 总结: 离散卡尔曼滤波

已知条件: **状态方程**  $\mathbf{x}(n) = \mathbf{A}(n-1)\mathbf{x}(n-1) + \mathbf{q}(n)$

**观测方程**  $\mathbf{y}(n) = \mathbf{C}(n)\mathbf{x}(n) + \mathbf{v}(n)$

初始化:  $\hat{\mathbf{x}}(0/0) = E\{\mathbf{x}(0)\}$ ,  $\mathbf{P}(0/0) = E\{\mathbf{x}(0)\mathbf{x}^H(0)\}$

递归估计算法:

1. **预测**  $\hat{\mathbf{x}}(n/n-1) = \mathbf{A}(n-1)\hat{\mathbf{x}}(n-1/n-1)$

2. **MSE**  $\mathbf{P}(n/n-1) = \mathbf{A}(n-1)\mathbf{P}(n-1/n-1)\mathbf{A}^H(n-1) + \mathbf{Q}_q(n)$

3. **增益**  $\mathbf{K}(n) = \mathbf{P}(n/n-1)\mathbf{C}^H(n) \left[ \mathbf{C}(n)\mathbf{P}(n/n-1)\mathbf{C}^H(n) + \mathbf{Q}_v(n) \right]^{-1}$

4. **修正**  $\hat{\mathbf{x}}(n/n) = \hat{\mathbf{x}}(n/n-1) + \mathbf{K}(n)[\mathbf{y}(n) - \mathbf{C}(n)\hat{\mathbf{x}}(n/n-1)]$

5. **MSE**  $\mathbf{P}(n/n) = [\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]\mathbf{P}(n/n-1)$

## § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

**例6.1:** 利用卡尔曼滤波估计一个未知的常数。设已知一个未知常数  $x$  的噪声观测集合, 已知噪声  $v(n)$  的均值为零, 方差为  $\sigma_v^2$ ,  $v(n)$  与  $x$  不相关, 试用卡尔曼滤波估计该常数。

解: 由于  $x$  不随时间  $n$  变化, 因此**状态方程**为:  $x(n) = x(n-1)$

而**观测方程**为:  $y(n) = x(n) + v(n)$

因此, 这时的  $A(n) = 1, C(n) = 1, Q_v(n) = \sigma_v^2, Q_q(n) = 0$ 。又  $x(n)$  是标量, 误差协方差也是标量, 可表示为:  $P(n/n) = E\{e^2(n/n)\}$  其中  $e(n/n) = x(n) - \hat{x}(n/n)$ 。这时的  $P(n/n-1)$  和  $P(n-1/n-1)$  是相等的, 即:  $P(n/n-1) = P(n-1/n-1)$

因此为表达简单, **我们将  $P(n/n-1)$  和  $P(n-1/n-1)$  都用  $P(n-1)$  来表示**。由卡尔曼增益表达式, 这时有:

$$K(n) = P(n-1) [P(n-1) + \sigma_v^2]^{-1}$$

### § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

$P(n/n)$  迭代公就为:

$$P(n) = [1 - K(n)]P(n-1) = \left[1 - \frac{P(n-1)}{P(n-1) + \sigma_v^2}\right] P(n-1) = \frac{P(n-1)\sigma_v^2}{P(n-1) + \sigma_v^2}$$

我们可以用递归的方式来求解上式的差分方程:

$$P(1) = \frac{P(0)\sigma_v^2}{P(0) + \sigma_v^2}, P(2) = \frac{P(1)\sigma_v^2}{P(1) + \sigma_v^2} = \frac{P(0)\sigma_v^2}{2P(0) + \sigma_v^2}, \\ P(3) = \frac{P(2)\sigma_v^2}{P(2) + \sigma_v^2} = \frac{P(0)\sigma_v^2}{3P(0) + \sigma_v^2}, \dots \rightarrow P(n) = \frac{P(0)\sigma_v^2}{nP(0) + \sigma_v^2}$$

将上式结合到卡尔曼增益  $K(n)$  的计算式中, 有:

$$K(n) = \frac{P(n-1)}{P(n-1) + \sigma_v^2} = \frac{P(0)}{nP(0) + \sigma_v^2}$$

最后得离散卡尔曼滤波器的计算式:

$$\hat{x}(n) = \hat{x}(n-1) + \frac{P(0)}{nP(0) + \sigma_v^2} [y(n) - \hat{x}(n-1)]$$

注意当  $n \rightarrow \infty$  时,  $K(n) \rightarrow 0$ , 因此  $\hat{x}(n)$  趋于稳态值。

## § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

---

**考虑两种较为极端的特殊情况。**

第一种情况, 若  $\sigma_v^2 \rightarrow \infty$ , 即观测值完全不可靠, 则卡尔曼增益趋于零, 估计公式变成:  $\hat{x}(n) = \hat{x}(n-1)$

因此, 观测值被忽略掉,  $\hat{x}(n) = \hat{x}(0)$ , 保持为初始估计, 误差方程为  $P(0)$ 。

第二种情况, 假设  $\hat{x}(0) = 0$ , 且  $P(0) \rightarrow \infty$ , 这相当于没有  $x$  的先验信息。这时  $K(n) = 1/n$ , 估计式变为:

$$\begin{aligned}\hat{x}(n) &= \hat{x}(n-1) + (1/n)[y(n) - \hat{x}(n-1)] \\ &= [(n-1)/n]\hat{x}(n-1) + (1/n)y(n)\end{aligned}$$

这实际上是递归地实现如下的采样均值计算:

$$\hat{x}(n) = \frac{1}{n} \sum_{k=1}^n y(k)$$

### § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

**例6.2:** 设  $x(n)$  是如下的 AR(1) 过程:  $x(n) = 0.8x(n-1) + w(n)$ , 其中  $w(n)$  是白噪声, 方差为  $\sigma_w^2 = 0.36$ 。又用  $y(n) = x(n) + v(n)$  表示信号  $x(n)$  的噪声观测,  $v(n)$  是单位方差的白噪声, 与  $w(n)$  不相关。

**解:** 这时的  $A(n) = 0.8$ ,  $C(n) = 1$ ,  $Q_v(n) = 1$ ,  $Q_q(n) = 0.36$ , **卡尔曼滤波的状态估计方程为:**

$$\hat{x}(n) = 0.8\hat{x}(n-1) + K(n)[y(n) - 0.8\hat{x}(n-1)]$$

**因状态变量是标量, 故卡尔曼增益计算公式也是标量方程:**

$$P(n/n-1) = (0.8)^2 P(n-1/n-1) + 0.36$$

$$K(n) = P(n/n-1)[P(n/n-1) + 1]^{-1}$$

$$P(n/n) = [1 - K(n)]P(n/n-1)$$

$$\text{取 } \hat{x}(0) = E\{x(0)\} = E\{w(n)\} = 0$$

$$P(0/0) = E\{|x(0)|^2\} = E\left\{\frac{|w(n)|^2}{1-0.8^2}\right\} = 1$$

### § 6.5.3 基于贝叶斯理论的离散卡尔曼滤波

前面几次迭代的卡尔曼增益和误差协方差如下表所示

n	P(n / n-1)	K(n)	P(n / n)
1	1.0000	0.5000	0.5000
2	0.6800	0.4048	0.4048
3	0.6190	0.3624	0.3824
4	0.6047	0.3768	0.3768
5	0.6012	0.3755	0.3755
⋮	⋮	⋮	⋮
∞	0.6000	0.3750	0.3750

可以看到，卡尔曼滤波器是**时变的**，且在  $n = 0$  时刻就开始工作。但因处理的是**平稳过程**，它在经历初始瞬变后，逐渐进入稳态行为：

$$\hat{x}(n) = 0.8\hat{x}(n-1) + 0.375[y(n) - 0.8\hat{x}(n-1)]$$


最后均方误差是  $\xi = 0.375$ 。



## §6.5.4 扩展卡尔曼滤波(EKF)

实际场景中我们经常遇到状态方程或观测方程是**非线性的**，例如运动目标的追踪问题。

$$R(n) = \sqrt{r_x^2(n) + r_y^2(n)}$$
$$\beta(n) = \arctan \frac{r_y(n)}{r_x(n)}$$



## §6.5.4 扩展卡尔曼滤波(EKF)

---

假设位置 $R(n)$ 和方位 $\beta(n)$ 在观测时分别受到噪声 $w_R(n)$ 和 $w_\beta(n)$ 的干扰, 即

$$\hat{R}(n) = R(n) + w_R(n)$$

$$\hat{\beta}(n) = \beta(n) + w_\beta(n)$$

如果存在状态方程:

$$r_x(n) = r_x(n-1) + v_x \Delta$$

$$r_y(n) = r_y(n-1) + v_y \Delta$$

那么位置 $R(n)$ 需要表示为

$$R(n) =$$

$$\sqrt{R^2(n-1) + 2R(n-1)\Delta(v_x \cos \beta(n-1) + v_y \sin \beta(n-1)) + (v_x^2 + v_y^2)\Delta^2}$$

定义 $\mathbf{y}(n) = [R(n), \beta(n)]^T$ 和 $\mathbf{x}(n) = [r_x(n), r_y(n)]^T$ , 则 $\mathbf{y}(n)$ 和 $\mathbf{x}(n)$ 之间**不存在**线性观测方程

$$\mathbf{y}(n) = \mathbf{C}(n)\mathbf{x}(n) + \mathbf{v}(n)$$

## §6.5.4 扩展卡尔曼滤波(EKF)

---

扩展卡尔曼滤波(EKF)的**状态方程**和**观测方程**:

$$\begin{cases} \mathbf{x}(n) = \mathbf{a}\{\mathbf{x}(n-1)\} + \mathbf{v}(n) \\ \mathbf{y}(n) = \mathbf{C}\{\mathbf{x}(n)\} + \mathbf{v}(n) \end{cases}$$

**求解方法:** 对状态转移函数 $\mathbf{a}\{\cdot\}$ 和观测函数 $\mathbf{C}\{\cdot\}$ 使用一阶泰勒展开得到近似值:

$$\begin{aligned} \mathbf{a}\{\mathbf{x}(n-1)\} &\approx \mathbf{a}\{\hat{\mathbf{x}}(n-1|n-1)\} \\ &+ \left. \frac{\partial \mathbf{a}}{\partial \mathbf{x}(n-1)} \right|_{\mathbf{x}(n-1)=\hat{\mathbf{x}}(n-1|n-1)} (\mathbf{x}(n-1) - \hat{\mathbf{x}}(n-1|n-1)) \\ \mathbf{C}(\mathbf{x}(n)) &\approx \mathbf{C}(\hat{\mathbf{x}}(n|n-1)) \\ &+ \left. \frac{\partial \mathbf{C}}{\partial \mathbf{x}(n)} \right|_{\mathbf{x}(n)=\hat{\mathbf{x}}(n|n-1)} (\mathbf{x}(n) - \hat{\mathbf{x}}(n|n-1)). \end{aligned}$$

## §6.5.4 扩展卡尔曼滤波(EKF)

### EKF递归估计算法:

1. 预测  $\hat{\mathbf{x}}(n/n-1) = \mathbf{a}\{(n-1)\hat{\mathbf{x}}(n-1/n-1)\}$
2. MMSE  $\mathbf{P}(n/n-1) = \mathbf{A}(n-1)\mathbf{P}(n-1/n-1)\mathbf{A}^H(n-1) + \mathbf{Q}_q(n)$
3. 增益  $\mathbf{K}(n) = \mathbf{P}(n/n-1)\mathbf{C}^H(n) \left[ \mathbf{C}(n)\mathbf{P}(n/n-1)\mathbf{C}^H(n) + \mathbf{Q}_v(n) \right]^{-1}$
4. 修正  $\hat{\mathbf{x}}(n/n) = \hat{\mathbf{x}}(n/n-1) + \mathbf{K}(n)[\mathbf{y}(n) - \mathbf{C}\{\hat{\mathbf{x}}(n/n-1)\}]$
5. MMSE  $\mathbf{P}(n/n) = [\mathbf{I} - \mathbf{K}(n)\mathbf{C}(n)]\mathbf{P}(n/n-1),$

$$\text{其中: } \begin{cases} \mathbf{A}(n-1) = \frac{\partial \mathbf{a}}{\partial \mathbf{x}(n-1)} \big|_{\mathbf{x}(n-1)=\hat{\mathbf{x}}(n-1|n-1)} \\ \mathbf{C}(n) = \frac{\partial \mathbf{C}}{\partial \mathbf{x}(n)} \big|_{\mathbf{x}(n)=\hat{\mathbf{x}}(n|n-1)} \end{cases}$$

**卡尔曼滤波器:** 卡尔曼增益 $\mathbf{K}(n)$ , 误差的协方差矩阵 $\mathbf{P}(n/n)$ ,  $\mathbf{P}(n/n-1)$ 与输入 $\mathbf{x}(n)$ 无关, 可以**离线**计算。

**扩展卡尔曼滤波器:** 卡尔曼增益 $\mathbf{K}(n)$  需要**在线**计算。

另一种非线性系统中常用的卡尔曼滤波算法: **无迹卡尔曼滤波(Unscented Kalman Filtering, UKF)**, 介绍从略。

# 总结

---

## 线性最优滤波器:

- (1)**最优FIR维纳滤波器**: 用于滤波、线性预测、噪声抑制、反卷积等; 格型结构实现。
- (2)**IIR维纳滤波器**: 非因果和因果。用于滤波、线性预测、反卷积等。
- (3)**离散卡尔曼滤波器**: 对平稳和非平稳过程都适用的递归估计, 可在  $n = 0$  时刻开始工作。
- **若希望放宽对  $x(n)$  和  $d(n)$  的统计量的已知条件, 就需自适应滤波器。**

**非线性系统:** 采用**扩展卡尔曼滤波 (EKF)** 或**无迹卡尔曼滤波 (UKF)** 更为有效。